

Implementación de Redes Neuronales Profundas para el Control de Calidad Automatizado y Detección de Micro fisuras en Envases de Vidrio.

Autor: Raúl Perú Porras Hurtado

Profesor: C. Marino Del Rosario, Ph.D

Fecha: 19 de febrero del 2026

1. Resumen Ejecutivo

El presente proyecto aborda la problemática de control de calidad en la planta FAENVIPE, donde la inspección manual de envases de vidrio presenta riesgos de seguridad y una merma considerable debido a la dificultad de detectar micro fisuras estructurales. El objetivo central fue desarrollar un sistema automatizado capaz de clasificar defectos (Burbujas, Grietas y Manchas) para reducir el desperdicio en un 15% durante el primer semestre de implementación.

La metodología empleada consistió en el desarrollo de una Red Neuronal Artificial (Deep Learning) utilizando Keras y TensorFlow, comparando su desempeño frente a modelos de Machine Learning tradicional (Random Forest y Regresión Logística). Ante un desbalance de datos de 10:1, se implementó una estrategia de Pesos de Clase (Class Weights) para mitigar el sesgo del modelo, asegurando que las fallas críticas no fueran ignoradas por el sistema.

Los principales hallazgos revelaron que, mediante el balanceo, el modelo logró identificar correctamente 341 grietas que anteriormente pasaban desapercibidas (elevando el Recall de 0.00 a 0.23), manteniendo una precisión global del 80%. Asimismo, mediante el análisis de interpretabilidad SHAP, se identificó que la velocidad de la cinta y la temperatura del horno son los factores determinantes en la generación de fallas estructurales.

El impacto esperado en el negocio incluye una reducción significativa en las devoluciones por rotura de envases en la cadena de suministro y una optimización del flujo de producción al clasificar correctamente el 97% del producto conforme. Este sistema sienta las bases para la transición de FAENVIPE hacia la Industria 4.0, garantizando una producción más segura y rentable.

2. Introducción

En la industria del vidrio, la calidad estructural es innegociable. Los defectos como las micro fisuras (grietas) comprometen la seguridad del consumidor y la reputación de la marca. Este informe detalla la transición de un sistema de inspección tradicional hacia uno basado en Inteligencia Artificial, integrando

técnicas de interpretabilidad para entender los factores térmicos y mecánicos que afectan la producción en FAENVIPE.

3. Definición del Problema

La planta FAENVIPE enfrenta dos retos principales:

1. **Fatiga de Inspección:** El ojo humano no puede detectar micro fisuras de forma constante a altas velocidades de cinta.
2. **Sesgo de Datos:** Al ser la mayoría de los envases "aptos", los modelos de IA iniciales tendían a ignorar los defectos raros pero peligrosos, generando una falsa sensación de seguridad con una precisión inflada.

4. Objetivos

4.1 Objetivo General

Implementar una Red Neuronal Artificial para la detección y clasificación multiclase de defectos en envases de vidrio.

4.2 Objetivos Específicos

- Reducir la merma operativa en un 15% en el primer semestre.
- Lograr una detección efectiva de al menos el 20% de las grietas estructurales.
- Identificar las variables de proceso (temperatura/velocidad) con mayor impacto en la calidad.

5. Marco Teórico

- **Deep Learning:** Uso de redes neuronales multicapa para encontrar patrones no lineales en datos de sensores.
- **Desbalance de Clases:** Fenómeno donde la clase mayoritaria (envases sanos) domina el aprendizaje.
- **SHAP (SHapley Additive exPlanations):** Método basado en teoría de juegos para explicar qué variables influyen en la decisión del modelo.

6. Metodología

1. **Recolección:** Procesamiento de un dataset de 100,000 registros de producción.
2. **Preprocesamiento:** Escalado de variables mediante *StandardScaler* para normalizar rangos de temperatura y presión.

3. **Tratamiento de Datos:** Aplicación de *Class Weights* para penalizar el error en la clase "Grieta".
4. **Entrenamiento:** Uso de una arquitectura secuencial con optimizador Adam.

7. Desarrollo del Modelo (Arquitectura)

Se diseñó una Red Neuronal en Keras con las siguientes especificaciones:

- **Capa de Entrada:** Ajustada al número de sensores de la planta.
- **Capas Ocultas:** Dos capas densas con activación **ReLU** para capturar la complejidad térmica.
- **Regularización:** Capas de **Dropout (0.2)** para evitar que el modelo memorice datos específicos (overfitting).
- **Capa de Salida:** Activación **Softmax** para clasificar entre: *Ninguno, Burbuja, Grieta y Mancha*.

8. Análisis de Resultados

8.1 Rendimiento Técnico

El modelo alcanzó una precisión global del **79.74%**. El avance crítico fue el aumento del **Recall de Grietas a 0.23**, lo que significa que el sistema ya no es "ciego" ante las fallas estructurales.

8.2 Comparación de Modelos

- **Random Forest:** 80.33% (Alta precisión en datos tabulares).
- **Deep Learning (Keras):** 79.74% (Seleccionado por su escalabilidad futura).
- **Regresión Logística:** 76.92% (Descartado por simplicidad).

9. Interpretación de Negocios

9.1 Insights Principales

- **Seguridad:** La detección de 341 grietas adicionales reduce drásticamente el riesgo de explosión de envases en las máquinas llenadoras de los clientes.
- **Factores Clave:** Según SHAP, la **velocidad de la cinta** es el factor más inestable, sugiriendo que las vibraciones mecánicas generan más grietas que la temperatura misma.

10. Conclusiones y Recomendaciones

1. **Conclusión:** Se logró romper el sesgo de datos, priorizando la detección de grietas críticas sobre la precisión general.
2. **Recomendación a Corto Plazo:** Estabilizar los motores de la cinta transportadora para reducir picos de velocidad.
3. **Recomendación a Largo Plazo:** Integrar cámaras térmicas para evolucionar el modelo hacia Visión Artificial (CNN).

11. Referencias

1. Chollet, F. (2021). Deep Learning with Python (2nd ed.). Manning Publications.
2. Géron, A. (2019). Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow: Concepts, Tools, and Techniques to Build Intelligent Systems. O'Reilly Media.
3. Lundberg, S. M., & Lee, S. I. (2017). A Unified Approach to Interpreting Model Predictions. Advances in Neural Information Processing Systems, 30.
4. Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., ... & Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. Journal of Machine Learning Research, 12, 2825-2830.
5. He, H., & Ma, Y. (Eds.). (2013). Imbalanced Learning: Foundations, Algorithms, and Applications. Wiley-IEEE Press.
6. Abadi, M., Agarwal, A., Barham, P., Brevdo, E., Chen, Z., Citro, C., ... & Zheng, X. (2015). TensorFlow: Large-Scale Machine Learning on Heterogeneous Systems.